

Analisis de resenas de Battlefield 6 en Steam

Memoria Tecnica del Pipeline de Analisis

Analitica de Datos en la Web y Redes Sociales

Grado en Ingenieria Informatica

Mayo 2026

Preguntas de investigacion:

- 1. Que caracteristicas de Battlefield 6 generan mayor satisfaccion o insatisfaccion entre los jugadores de Steam?*
- 2. Como evoluciona el sentimiento de la comunidad a lo largo del tiempo desde el lanzamiento hasta mayo de 2026?*

1. Dataset y pregunta de investigacion [1,0 pt]

1.1 Preguntas de investigacion

El proyecto parte de dos preguntas de investigacion complementarias que orientan todas las decisiones metodologicas posteriores:

- PREGUNTA PRINCIPAL: "Que características de Battlefield 6 generan mayor satisfaccion o insatisfaccion entre los jugadores de Steam, y como evoluciona el sentimiento de la comunidad a lo largo del tiempo?"
- PREGUNTA SECUNDARIA: "Que aspectos del juego aparecen con mayor frecuencia en las resenas negativas de Battlefield 6 en Steam y que diferencia a los jugadores que recomiendan el juego de los que no lo recomiendan?"

Estas preguntas encajan en la categoria 'Amazon u otra tienda' del rubric de la asignatura: Steam es esencialmente una tienda de videojuegos y sus resenas son equivalentes a las valoraciones de producto de cualquier plataforma de comercio electronico. Cada resena incluye un voto binario (pulgar arriba/abajo), texto libre y metadatos de uso, analogos a las valoraciones por estrellas con comentario de Amazon.

1.2 Por que Steam como fuente de datos

La API publica de Steam (endpoint: store.steampowered.com/appreviews/2807960, donde 2807960 es el App ID de Battlefield 6) ofrece varias ventajas decisivas frente a otras fuentes alternativas como Twitter/X, Reddit o foros de usuarios:

- API OFICIAL Y PUBLICA: No requiere autentificacion ni clave de API. Las peticiones son reproducibles por cualquier investigador. Esto garantiza la trazabilidad del dataset.
- DATOS RICOS Y ESTRUCTURADOS: Cada resena incluye no solo el texto libre sino tambien metadatos cuantitativos (horas jugadas, voto de utilidad de la comunidad, fecha exacta) que permiten analisis de engagement imposibles con otras fuentes.
- VOLUMEN ELEVADO: 168.341 resenas en bruto, 91 veces el umbral minimo del rubric (1.000). Esto garantiza suficiente representatividad estadistica para todos los subgrupos de analisis.
- GROUND TRUTH INTEGRADO: El campo voted_up (pulgar arriba/abajo) proporciona una etiqueta de sentimiento binaria asignada por el propio autor, sin necesidad de anotacion manual. Es el ground truth mas fiable disponible para este tipo de corpus.
- COBERTURA TEMPORAL COMPLETA: El dataset abarca desde el lanzamiento del juego (octubre 2025) hasta mayo de 2026, cubriendo el ciclo de vida inicial completo con eventos clave como el lanzamiento de DLCs y parches.

1.3 Volumen y periodo del dataset

Metrica	Valor
Resenas extraidas (raw)	168.341
Resenas limpias (tras preprocesamiento)	91.197
Tasa de retencion	54.2% (91.197 / 168.341)
Periodo de analisis	Octubre 2025 - Mayo 2026
Idioma del corpus	Ingles (filtrado por campo language de Steam)
App ID de Steam	2807960 (Battlefield 6)
Minimo requerido por el rubric	1.000 resenas
Factor sobre el minimo	91,2 veces el minimo

1.4 Variables del dataset limpio

El dataset final (battlefield6_reviews_clean.csv) contiene las siguientes variables, seleccionadas y transformadas del raw original para maximizar su utilidad analitica:

Variable	Descripcion	Uso en el analisis
voted_up	Pulgar arriba (True) o abajo (False) asignado por el autor de la resena	Ground truth para evaluar los modelos de sentimiento
playtime_hours	Horas jugadas por el autor en el momento de la resena (minutos / 60)	Variable de engagement en el analisis complementario
date	Fecha de publicacion de la resena (convertida desde Unix timestamp)	Analisis temporal semanal (graficos 09 y 10)
weighted_vote_score	Puntuacion ponderada de Steam (0 a 1) sobre la utilidad de la resena	Proxy de utilidad percibida por la comunidad
text_cleaned	Texto limpio y legible: minusculas, sin URLs ni caracteres especiales	Entrada a RoBERTa para el analisis de sentimiento
text_lemmatized	Texto lematizado, sin stopwords ni terminos de dominio gaming	Entrada al LDA para el modelado de temas

2. Obtencion y documentacion de datos [1,0 pt]

2.1 Mecanismo de extraccion: paginacion por cursor

El script `fetch_reviews.py` hace peticiones paginadas a la API de Steam usando el sistema de cursor. A diferencia de una paginacion clasica por numero de pagina (`page=1`, `page=2...`), la API de Steam devuelve en cada respuesta un token opaco llamado cursor que apunta internamente a la siguiente pagina de resultados. Este diseno evita problemas de paginas solapadas cuando se insertan nuevas resenas durante la extraccion.

El bucle de extraccion funciona de la siguiente manera: se hace una primera peticion con `cursor=*` (inicio), se reciben hasta 100 resenas por peticion, se extrae el nuevo cursor de la respuesta y se usa en la siguiente peticion. El bucle termina cuando el cursor recibido es identico al de la peticion anterior o viene vacio, lo que indica que se han agotado todas las paginas disponibles:

```
if not new_cursor or new_cursor == cursor:
    print("Cursor sin cambios, fin de la extraccion.")
    break
```

2.2 Uso responsable: `time.sleep(1)`

Entre cada peticion a la API hay una pausa explicita de 1 segundo (`time.sleep(1)`). Esta decision cumple el requisito etico del rubric de 'evitar scraping agresivo'. La razon tecnica y etica es doble: por un lado, se respetan los servidores de Steam limitando las peticiones a una por segundo, evitando que la herramienta pueda interpretarse como un ataque de denegacion de servicio (DoS); por otro lado, la API de Steam tiene rate limits no documentados publicamente, y hacer peticiones demasiado rapidas puede resultar en bloqueos temporales de la IP. Con 168.341 resenas y 100 resenas por peticion, se necesitan aproximadamente 1.684 peticiones, lo que supone un tiempo de extraccion de unos 28 minutos, tiempo perfectamente aceptable para un proyecto academico.

2.3 Campos extraidos de la API

Por cada resena, la API devuelve un objeto JSON del que se extraen los siguientes campos y se realizan las conversiones necesarias:

Campo API	Tipo original	Transformacion aplicada
review_id	Entero	Identificador unico, no se usa en analisis
review (text)	String	Campo principal; se limpia y lematiza
language	String	Filtro: solo se conservan 'english'
voted_up	Boolean	Ground truth para evaluacion de modelos

timestamp_created	Unix epoch (int)	pd.to_datetime(..., unit='s') -> fecha
playtime_forever	Minutos (int)	Dividido entre 60, redondeado a 2 decimales
votes_helpful	Entero	No usado en analisis final
votes_funny	Entero	No usado en analisis final
weighted_vote_score	Float 0-1	Proxy de utilidad en analisis de engagement

2.4 Limitacion documentada: el problema del campo language

El campo language de la API de Steam refleja el idioma configurado en el cliente Steam del usuario, NO el idioma real del texto de la resena. Esto tiene una consecuencia importante: un jugador hispanohablante que tiene su cliente Steam configurado en ingles escribira su resena en espanol, pero el campo language indicara 'english'. El filtro del script (language == 'english') no puede detectar estos casos.

Se evaluo usar la libreria langdetect para detectar automaticamente el idioma real del texto y rechazar las resenas no inglesas. Sin embargo, langdetect fue descartada por dos razones tecnicas concretas:

- Alta tasa de falsos positivos en textos cortos: texto ingles perfectamente valido y fluido de 10-15 palabras es clasificado como somali, aleman o catalan con frecuencia preocupante. Con reseñas de Steam que pueden tener solo 1-2 frases, el problema es especialmente grave.
- La clasificacion erronea eliminaria resenas validas del corpus, reduciendo el volumen de datos sin garantia de mayor pureza linguistica.

LIMITACION DOCUMENTADA: Algunas resenas en portugues o espanol pasan el filtro porque Steam las clasifica como 'english' segun la configuracion del cliente. En los ejemplos representativos del LDA aparecen ocasionalmente resenas en portugues y espanol, lo que confirma la presencia de este ruido. Su impacto en un corpus de 91.197 resenas es marginal y no afecta significativamente a los resultados del analisis tematico.

3. Preprocesamiento [1,5 pt]

3.1 Por que spaCy y no NLTK

El rubric no exige una libreria de NLP concreta; la eleccion de spaCy (modelo en_core_web_sm) frente a NLTK responde a dos ventajas tecnicas especificas relevantes para este proyecto:

- LEMATIZACION CONTEXTUAL: spaCy realiza tokenizacion y lematizacion en una sola pasada sobre el documento mediante un pipeline interno que incluye POS tagging (etiquetado de categorias gramaticales). Esto permite lematizar correctamente segun el contexto: la palabra 'better' se convierte en 'good' si el POS tag es adjetivo (ADJ), pero en 'better' si se usa como verbo auxiliar. NLTK con PorterStemmer solo trunca morfológicamente ('running' -> 'run' por corte del sufijo '-ing') sin entender el contexto gramatical, lo que genera formas base incorrectas con frecuencia.
- STOPWORDS INTEGRADAS: spaCy tiene un modelo preentrenado con las stopwords del ingles integradas como propiedad del token (token.is_stop = True/False), por lo que no es necesario gestionar ni importar una lista separada. Ademas, el criterio de stopword tiene en cuenta el contexto morfosintactico del token, no solo la forma de la palabra.
- VELOCIDAD: El modelo en_core_web_sm esta compilado en Cython y es significativamente mas rapido que las alternativas puras de Python de NLTK para corpus grandes.

3.2 Bloque 1 - Filtrado de resenas (antes de procesar el texto)

Antes de transformar el texto, el codigo descarta resenas enteras que no aportaran nada util al analisis. Este filtrado previo evita malgastar tiempo de CPU/GPU en la lematizacion y la inferencia de RoBERTa sobre resenas que de todos modos se eliminarian despues. Se aplican cuatro filtros en cascada:

FILTRO 1 - Idioma:

Se comprueba el campo language de cada fila del JSON raw. Si no es 'english' (ignorando mayusculas y espacios), la resena se descarta. El valor por defecto si el campo falta es 'english' para no eliminar resenas validas por un campo ausente en la API. Este filtro elimina las 2 resenas explicitamente en japones y turco que aparecian en el dataset raw.

FILTRO 2 - Emojis puros:

Algunas resenas de Steam consisten literalmente en uno o varios emojis sin ningun texto (por ejemplo, solo tres llamas o un pulgar arriba). Estas resenas no aportan informacion textual para ni RoBERTa ni el LDA. El filtro aplica una regex que cubre los rangos Unicode U+1F300-U+1FAFF y comprueba si queda algun caracter alfanumerico tras eliminar los emojis. Si el texto resultante esta vacio, la resena se descarta.

FILTRO 3 - Calidad minima (5 palabras):

Se requieren al menos 5 palabras en el texto limpio. Esta condicion descarta: resenas de una o dos palabras ('good game', 'trash'), resenas compuestas solo de numeros y simbolos ('10/10!!!') que no aportan texto analizabe, y resenas de spam donde una misma palabra se repite mas de 5 veces. El umbral de 5 palabras es el minimo razonable para que RoBERTa tenga suficiente contexto y para que el LDA asigne un tema con cierta fiabilidad.

FILTRO 4 - Spam (palabra repetida > 5 veces):

Se usa Counter(words).values() y se comprueba que el maximo no supera 5. Esto elimina resenas tipo 'hahahahahahaha' o '!!!!!!!!!!!!!!' que son ruido puro y podrian distorsionar las distribuciones de palabras del LDA si se incluyeran en el corpus.

3.3 Bloque 2 - Limpieza del texto

El texto crudo que pasa los filtros anteriores se limpia en cuatro pasos secuenciales. El resultado se guarda en la columna text_cleaned, que es la version que usa RoBERTa:

Operacion	Tecnica	Justificacion
Minusculas	text.lower()	Normaliza 'Game', 'GAME' y 'game' a la misma forma.

Necesario antes de cualquier comparacion lexica.

Eliminar URLs	regex <code>https?://S+ www\.\S+</code> sustituida por espacio	Los enlaces no aportan contenido semantico. Se sustituye por espacio (no vacio) para no fusionar las palabras adyacentes.
Eliminar caracteres especiales	regex <code>[^a-z0-9\s.,;:?!]</code> sustituida por espacio	Conserva letras, numeros y puntuacion basica. Los hashtags se eliminan: en Steam no tienen valor tematico como en Twitter.
Colapsar espacios	regex <code>\s+ -> ' '</code>	Elimina espacios multiples, tabs y saltos de linea resultantes de los pasos anteriores.

3.4 Bloque 3 - Lematizacion y gestion de negaciones

El texto limpio se procesa con spaCy para generar la columna `text_lemmatized`, que es la que usa el LDA. Este paso tiene una complejidad adicional respecto a una lematizacion estandar: la gestion de las negaciones.

EL PROBLEMA DE LAS NEGACIONES:

Si se lematiza y eliminan stopwords de manera estandar, 'not' desaparece porque es una stopwords en spaCy. El resultado es que 'the game is not good' y 'the game is good' producen exactamente el mismo texto lematizado: 'game good'. El LDA no podria distinguir entre una valoracion positiva y una negativa sobre la misma caracteristica, lo que contaminaria los temas.

LA SOLUCION: BIGRAMAS `not_X`:

El bucle de lematizacion usa un indice manual (`while i < len(tokens)`) en lugar de un for convencional, porque necesita la capacidad de saltar tokens. Cuando encuentra el token 'not' seguido de una palabra que no es puntuacion, construye un bigrama concatenando 'not_' con el lema del token siguiente y avanza el indice en 2 posiciones en lugar de 1. Ejemplos de la transformacion:

- "not good" -> `not_good` (aparece en resenas negativas sobre calidad general)
- "not working" -> `not_work` (aparece en resenas sobre fallos tecnicos)
- "not fun" -> `not_fun` (aparece en resenas criticas con la experiencia de juego)
- "not bad" -> `not_bad` (aparece en resenas positivas moderadas)

Para los tokens que no son parte de una negacion se aplican cuatro filtros acumulativos: `is_stop` elimina stopwords del ingles; `is_punct` elimina puntuacion; `len(lemma) >= 3` elimina tokens de 1-2 caracteres que son casi siempre ruido; y `lemma_` devuelve la forma base del token segun su POS tag contextual.

3.5 Bloque 4 - Gaming Stopwords (stopwords de dominio)

spaCy elimina las stopwords del ingles general, pero no sabe que en este corpus concreto ciertas palabras son igualmente poco informativas. Palabras como 'game', 'play' o 'battlefield' aparecen en practicamente TODAS las resenas de Steam de cualquier Battlefield, sin discriminar entre temas. Si se dejan en el vocabulario, el LDA las encontrara con peso alto en todos los temas simultaneamente, enturbiando la separacion semantica entre ellos. Esto se conoce como stopwords de dominio y es una decision metodologica especifica del proyecto.

Lista completa de Gaming Stopwords anadidas:

- Terminos genericos del videojuego: game, play, battlefield, fun, great, good, bad
- Verbos auxiliares muy frecuentes: get, make, go, think, know, want, need, give, come, look, say
- Nombres propios del ecosistema Battlefield: bf, ea, dice
- Sustantivos abstractos sin valor discriminativo: lot, time, way, thing, people, player, year
- Adjetivos y adverbios genericos: like, feel

El parametro `NO_ABOVE=0.40` en Gensim actua como una tercera capa de filtrado: cualquier termino que aparezca en mas del 40% de los documentos se elimina automaticamente del vocabulario del LDA, independientemente de si esta en

las Gaming Stopwords o no. Las tres capas (spaCy stopwords + Gaming Stopwords + NO_ABOVE) se complementan.

3.6 Resultado del preprocesamiento

De 168.341 reseñas raw se pasa a 91.197 reseñas limpias (tasa de retención: 54.2%). Las aproximadamente 77.000 reseñas eliminadas corresponden a:

- Reseñas de idioma no inglés (campo language != 'english'): 2 reseñas (japones, turco)
- Reseñas con menos de 5 palabras tras la limpieza: la mayoría de las eliminadas
- Reseñas de solo emojis o de solo números/símbolos: varios miles
- Reseñas con spam repetitivo (palabra repetida > 5 veces): algunas centenas
- Reseñas cuya lematización produce texto vacío (texto que era 100% stopwords): residual

4. Analisis de sentimiento [1,5 pt]

4.1 Por que dos modelos

El rubric requiere al menos un modelo de analisis de sentimiento. Se implementaron dos (VADER y RoBERTa) por una razon metodologica concreta: poder comparar cuantitativamente cual funciona mejor sobre ESTE corpus especifico, con metricas reales calculadas frente al mismo ground truth. El modelo ganador (RoBERTa) se usa como columna principal (roberta_sentiment). VADER queda en el CSV para comparacion y como ilustracion de las limitaciones de los enfoques basados en diccionario.

4.2 Modelo 1 - VADER (Valence Aware Dictionary and sEntiment Reasoner)

VADER no es un modelo de machine learning. Es un DICCIONARIO LEXICO CON REGLAS. Fue desarrollado en 2014 por Hutto y Gilbert especificamente para texto de redes sociales. Contiene una lista de aproximadamente 7.500 palabras con puntuaciones de valencia asignadas manualmente por un panel de humanos mediante crowdsourcing (ejemplo: 'terrible' = -3.4, 'amazing' = 3.1, 'not' = -0.74). Cuando recibe un texto, VADER:

- Suma las puntuaciones de valencia de todas las palabras que reconoce en el diccionario
- Aplica cinco heurísticas modificadoras: mayusculas intensifican el sentimiento (+/- 0.733), signos de exclamacion aumentan la intensidad, 'but' da mas peso a la segunda clausula, 'not/never/no' invierten el signo del siguiente token, y trigramas como 'kind of' atenuan
- Normaliza el resultado a una escala de -1 a +1 (score compound)
- Clasifica: compound ≥ 0.05 -> positivo, ≤ -0.05 -> negativo, resto -> neutral

VENTAJA: instantaneo, sin GPU, sin descarga de modelos, interpretable. LIMITACION ESTRUCTURAL: no entiende contexto real de la frase. Puntua token por token. 'This game is not bad at all' puede salir mal porque VADER aplica reglas fijas para 'not' y 'bad' sin entender la construccion de doble negacion ni la intencion comunicativa global. En textos informales con sarcasmo o jerga gaming ('this game is cancer' = muy negativo en el contexto de gaming, pero 'cancer' no aparece con ese sentido en el diccionario de VADER), el rendimiento cae notablemente.

4.3 Modelo 2 - RoBERTa (el modelo principal)

cardiffnlp/twitter-roberta-base-sentiment es un TRANSFORMER. Concretamente es RoBERTa-base (una variante optimizada de BERT) fine-tuneado sobre aproximadamente 58 millones de tweets en ingles para clasificar sentimiento en tres clases: LABEL_0 (negativo), LABEL_1 (neutral) y LABEL_2 (positivo). A diferencia de VADER, RoBERTa procesa la frase completa como una unidad. Internamente representa cada token como un vector de 768 dimensiones que codifica su significado EN EL CONTEXTO de las palabras que lo rodean mediante capas de atencion. 'Not bad' y 'bad' producen representaciones completamente distintas porque el modelo ha aprendido esa construccion sobre millones de ejemplos reales.

POR QUE ESTE MODELO ESPECIFICO (twitter-roberta):

- Esta entrenado en tweets, que son textos informales, cortos y llenos de jerga, exactamente igual que las resenas de Steam. Un modelo entrenado en noticias o articulos academicos (como BERT-base sin fine-tuning) renderia peor en este corpus.
- Tiene TRES clases (positive/neutral/negative) en lugar de dos (positive/negative). Esto es mas adecuado para resenas donde el tono ambivalente es muy frecuente: un jugador puede estar satisfecho con el gameplay pero frustrado con la monetizacion en la misma resena.
- Es un modelo de tamano mediano (125M parametros) que cabe perfectamente en la VRAM de la RTX 4070 (8GB) con batch_size=32, optimizando el tiempo de inferencia.

EL LIMITE DE 512 TOKENS - causa y solucion:

RoBERTa tiene un limite fisico de 512 tokens de entrada por diseno arquitectonico. El mecanismo de atencion tiene coste cuadratico con la longitud de la secuencia: duplicar la longitud cuadruplica el coste computacional y la memoria. Este limite fue una decision de diseno para hacer los transformers viables en el hardware disponible cuando se crearon

(2019). Una resena larga de Steam puede tener perfectamente 800-1000 tokens. La solución adoptada es `truncation=True, max_length=512`: las resenas largas se truncan a los primeros 512 tokens. La hipótesis, generalmente válida, es que los autores expresan su opinión general al comienzo del texto. Es una limitación que se documenta explícitamente en la sección de limitaciones.

INFERENCIA EN BATCHES CON GPU:

Con `BATCH_SIZE=32`, se procesan 32 resenas simultáneamente en la GPU. La diferencia de tiempo es enorme: en CPU, procesar 91.197 resenas una por una tardaría aproximadamente 8 horas. Con la GPU RTX 4070 (8GB VRAM, CUDA 12.4) con batches de 32, tarda entre 15 y 20 minutos. La GPU ejecuta 32 operaciones matriciales en paralelo porque está diseñada para ello (miles de núcleos CUDA vs decenas de núcleos CPU). `device=0` indica a HuggingFace que use la primera GPU disponible; si no hay GPU, `device=-1` fuerza la ejecución en CPU.

LA PUNTUACION COMPUESTA `roberta_compound`:

El modelo devuelve una etiqueta categorica (`positive/neutral/negative`) y un score de confianza entre 0 y 1. Con eso solo se tiene información categorica, insuficiente para análisis de correlación con variables numericas continuas (horas jugadas, fecha, vote score). Se construye la variable `roberta_compound` entre -1 y +1: si la etiqueta es 'positive', el compound es `+score` (positivo con 95% de confianza -> `+0.95`); si es 'negative', el compound es `-score` (negativo con 80% -> `-0.80`); si es 'neutral', el compound es 0.0. Esto es analogo al compound de VADER y permite tratar el sentimiento como una variable continua en todos los análisis posteriores.

4.4 Metricas de evaluacion y comparativa

Para evaluar ambos modelos se usa `voted_up` como GROUND TRUTH. La lógica es: si un jugador pulso el pulgar arriba, asumimos que su resena expresa sentimiento positivo; si pulso pulgar abajo, sentimiento negativo. Se hace clasificación binaria: RoBERTa 'positive' = True, cualquier otra clase (neutral o negative) = False.

Metrica	VADER	RoBERTa (modelo principal)
Tipo de modelo	Diccionario lexico + reglas heurísticas	Transformer fine-tuned (58M tweets)
Accuracy	68.85%	78.87%
Precision	76.77%	93.58%
Recall	71.58%	70.90%
F1-score	74.08%	80.68%

INTERPRETACION DE LAS METRICAS:

- Accuracy 78.87% vs 68.85%: RoBERTa acierta en 10 puntos porcentuales más de resenas. Diferencia sustancial considerando que el corpus tiene 91.197 ejemplos.
- Precision 93.58%: cuando RoBERTa dice que una resena es positiva, casi siempre tiene razón. Muy pocos falsos positivos. VADER tiene 16 puntos menos de precisión (76.77%).
- Recall 70.90% (similar en ambos): muchas resenas donde el jugador voto positivo (`voted_up=True`) tienen texto con sentimiento mixto o negativo. El modelo las clasifica como negativas o neutrales, lo que cuenta como fallo de recall aunque el modelo puede estar 'en lo correcto' respecto al texto.

El recall bajo (70.9%) NO es un error del modelo sino una limitación del ground truth. Steam pregunta '¿Recomiendas este juego?' (voto binario global) mientras que RoBERTa mide el TONO EMOCIONAL del texto, que son preguntas distintas. Ejemplo real: 'the servers crash constantly and the monetization is disgusting, but it is still the best Battlefield since BF4' -> Steam: positivo (recomienda); RoBERTa: negativo (tono predominantemente negativo). El modelo capta la realidad del texto; el ground truth captura la recomendación global del jugador. Esta discrepancia es en si misma un hallazgo analítico relevante.

4.5 Validacion manual (41 resenas anotadas)

El script `manual_validation.py` genera una muestra estratificada de 45 resenas dividida en tres grupos: acuerdo positivo

(RoBERTa y voted_up coinciden en positivo), acuerdo negativo y desacuerdo (divergen). El objetivo es identificar PATRONES DE ERROR del modelo que las metricas globales no revelan. Se anotaron 41 de las 45 resenas:

Grupo	N	Resultado
Coincidencia positiva (RoBERTa = Steam = positivo)	15	15/15 (100%) de acuerdo
Coincidencia negativa (RoBERTa = Steam = negativo)	15	15/15 (100%) de acuerdo
Desacuerdo (casos difciles para el modelo)	11	3/11 (27%) de acuerdo
TOTAL anotado	41	33/41 (80%) de acuerdo global

PATRONES DE ERROR IDENTIFICADOS EN EL GRUPO DE DESACUERDO:

- SARCASMO: 'buy baitandswitch 6 [...] servers hosted with windows 95' -> RoBERTa lo clasifica como positivo leyendo literalmente 'buy' como acto de compra voluntaria. El sarcasmo requiere conocimiento del contexto cultural que el modelo no tiene.
- HIPERBOLE GAMING: 'getting bent over a table by an attack helicopter [...] i love this game' -> el texto es muy negativo en tono pero el jugador vota positivo. El modelo no entiende que en la cultura gaming la queja hiperbólica puede coexistir con el disfrute.
- REFERENCIA CULTURAL IMPLICITA: 'just like the good ol days' -> RoBERTa dice neutral. Sin saber que hace referencia positiva a BF3/BF4, la frase parece ambigua.
- HUMOR ABSURDO: 'id play with my dead grandma but shes dead so that wont work' -> ni el modelo ni el anotador humano pueden determinar el sentimiento con certeza. Estos casos ilustran los limites del analisis de sentimiento automatico.

5. Modelado de temas - LDA (Gensim) [1,5 pt]

5.1 Que es LDA y que resuelve

LDA (Latent Dirichlet Allocation) es el algoritmo que responde a: 'de que hablan las resenas?'. Con 91.197 resenas imposibles de leer manualmente, LDA las agrupa automaticamente por temas sin que el usuario defina cuales son esos temas de antemano: los descubre solo a partir de las co-ocurrencias estadisticas de palabras en el corpus.

LDA es un MODELO GENERATIVO que parte de dos suposiciones fundamentales sobre como se escribe un texto: (1) cada documento habla de varios temas a la vez con distintas proporciones (una resena puede ser 60% comparacion con entregas anteriores y 40% monetizacion), y (2) cada tema se caracteriza por una distribucion de probabilidad sobre el vocabulario (el tema de monetizacion tiene alta probabilidad para palabras como 'pay', 'skin', 'money' y baja para palabras como 'tank' o 'spawn').

El entrenamiento hace el proceso INVERSO al generativo: dadas las palabras observadas en el corpus, encuentra que combinacion de distribucion de temas por documento y distribucion de palabras por tema las explica mejor, usando inferencia variacional iterativa (metodo de Bayes variacional). El modelo converge cuando las asignaciones de temas dejan de cambiar significativamente entre iteraciones.

5.2 Bag-of-words: que se pierde y por que no importa

LDA trabaja sobre representaciones bag-of-words (BoW): cada resena se convierte en un vector de frecuencias de palabras sin preservar el orden. 'The game is good' y 'good is the game' producen exactamente la misma representacion BoW. Lo que se pierde es el orden de las palabras, es decir, las relaciones sintacticas y la estructura de la frase. Sin embargo, para la tarea de descubrir TEMAS esto no importa porque lo que distingue un tema de otro es que ciertos grupos de palabras co-ocurren frecuentemente en los mismos documentos: las palabras 'pay', 'skin', 'battlepass', 'money', 'season' aparecen juntas en las resenas sobre monetizacion independientemente del orden en que el autor las escribio. El orden es irrelevante para esta senyal.

5.3 Preparacion del vocabulario: filter_extremes

Antes de entrenar el LDA, se construye el diccionario de Gensim y se filtra con filter_extremes(no_below=10, no_above=0.40). Este es uno de los pasos mas criticos del pipeline:

- NO_BELOW=10: se eliminan los tokens que aparecen en menos de 10 documentos. Con 91k resenas, si una palabra aparece solo en 3-4, es casi con certeza una errata, un neologismo muy raro o un termino tan especifico que no puede generar un tema coherente. No tiene suficiente informacion estadistica para que el LDA la use de forma fiable.
- NO_ABOVE=0.40: se eliminan los tokens que aparecen en mas del 40% de los documentos. Este fue el parametro MAS CRITICO del proyecto. El valor original era 0.70, que dejaba pasar palabras como 'game' (que aparece en ~55% de los docs) o 'play' (~45%). Con ese valor, el 98% de las 3.227 resenas que habia en ese momento (antes del bug de RoBERTa) cayan en un solo tema porque el modelo encontraba esas palabras ubicuas en todas partes y las usaba como ancla. Bajarlo a 0.40 forzo al modelo a buscar vocabulario mas especifico y discriminativo para separar los temas.

BUG CRITICO DETECTADO Y RESUELTO: en un punto del desarrollo, el CSV de sentimiento tenia solo 3.227 filas en lugar de 91.197. La causa fue que el compañero ejecuto RoBERTa sobre un CSV de pruebas mas pequeño y luego regenero el CSV limpio sin volver a ejecutar RoBERTa. El LDA vio solo 3.227 resenas y el 98% cayeron en un tema. Tras detectar el bug, se reejecuto RoBERTa sobre las 91.197 resenas completas (~18 min con RTX 4070) y el LDA se reentrenó con los parametros corregidos, obteniendo un coherence score de 0.6434.

5.4 Parametros del modelo LDA y justificacion

Parametro	Valor	Justificacion detallada
-----------	-------	-------------------------

num_topics	5	Se probaron 4 y 6 temas. Con 4, dos temas tecnicamente distintos (problemas tecnicos y monetizacion) se fusionaban. Con 6, un tema extra era semanticamente redundante con otro. Con 5, el coherence score era maximo (0.6434) y los temas eran distinguibles.
passes	15	Con 10 pasadas los temas eran inestables entre ejecuciones (el random_state fijo no es suficiente si el modelo no converge). 15 pasadas garantiza convergencia para un corpus de 91k docs.
chunksize	2000	Numero de documentos procesados por iteracion. Valor original de 100 era ineficiente con 91k docs (demasiados microlotes). 2000 equilibra velocidad y calidad de convergencia.
NO_ABOVE	0.40	Filtra tokens en mas del 40% de documentos. Valor critico: 0.70 original causaba que el 98% de resenas cayeran en un tema.
NO_BELOW	10	Descarta tokens en menos de 10 resenas. Con 91k docs, requiere cierta frecuencia minima para tener senyal estadistica.
alpha='auto'	-	El modelo aprende la distribucion optima de temas por documento en lugar de asumir valores fijos (simetrico por defecto).
eta='auto'	-	El modelo aprende la distribucion optima de palabras por tema.
random_state	42	LDA es estocastico (inicializacion aleatoria de asignaciones). Semilla fija garantiza reproducibilidad exacta entre ejecuciones.

5.5 Coherence score c_v: 0.6434

El coherence score mide la calidad semantica de los temas descubiertos. Especificamente, c_v mide si las palabras mas representativas de cada tema co-ocurren frecuentemente en el corpus real. Si las palabras clave del tema de monetizacion ('pay', 'skin', 'money', 'battlepass') aparecen juntas frecuentemente en las resenas reales, el tema es semanticamente coherente y tiene sentido interpretarlo como una unidad tematica real.

Escala de referencia para c_v:

Rango c_v	Interpretacion
< 0.40	Malo: los temas no tienen coherencia semantica interpretable
0.40 - 0.50	Aceptable: temas distinguibles pero con solapamiento
0.50 - 0.60	Bueno: temas claros con vocabulario diferenciado
> 0.60	Muy bueno: temas altamente coherentes (nuestro resultado: 0.6434)

El resultado de 0.6434 valida cuantitativamente tanto la eleccion de 5 temas como los parametros del modelo. El calculo usa processes=1, obligatorio en Windows porque Gensim usa multiprocessing para calcular la coherencia en paralelo y hay un bug conocido en Windows con la serializacion de objetos de Gensim que lanza un error de pickle al usar mas de un proceso.

5.6 Los 5 temas descubiertos

DECISION METODOLOGICA IMPORTANTE: Las etiquetas de los temas se asignaron **DESPUES** de ver las palabras clave reales del modelo entrenado, no antes. En una version anterior del codigo los nombres estaban escritos antes de ejecutar el LDA, lo que es un error metodologico: se estarian nombrando resultados que aun no se han visto. Las etiquetas deben **EMERGER** de los datos, no precederlos.


#	Etiqueta asignada	Palabras clave reales del modelo	Resenas	%
0	Comparacion con entregas	cod, bf4, bf3, 2042, campaign,	49.958	54.8%
1	Mecanicas de combate y anti-cheat	kill, hit, tank, die, shoot, spawn, cheater,		

		cheat	4.451	4.9%
2	Mapas, armas y vehiculos	map, mode, gun, weapon, vehicle, big,	12.362	13.6%
3	Problemas tecnicos y servidores	not_fix, issue, bug, server, run, launch	15.386	16.9%
4	Monetizacion y Battlepass	battle, buy, skin, money, pass, pay, season	9.040	9.9%

El 76.1% de las reseñas tienen al menos un tema secundario (umbral de probabilidad: 0.20). Esto confirma que los jugadores raramente escriben sobre un unico aspecto del juego: una resena sobre la monetizacion frecuentemente menciona tambien problemas tecnicos o comparaciones con entregas anteriores. La multitematicidad es una característica estructural del corpus, no un artefacto del modelo.

5.7 Visualizacion pyLDAvis

pyLDAvis genera una visualizacion interactiva con dos paneles. El panel izquierdo muestra los 5 temas como círculos en un espacio bidimensional calculado con MDS (Multi-Dimensional Scaling). Las distancias entre círculos reflejan la similitud semantica entre temas: círculos alejados tienen vocabularios poco solapados (temas bien separados). El tamaño de cada círculo es proporcional al peso del tema en el corpus (el tema 0 es el mas grande porque representa el 54.8% de las reseñas). El panel derecho muestra los terminos mas relevantes del tema seleccionado, con la frecuencia global en gris y la frecuencia específica del tema en azul.



6. Analisis complementario [1,0 pt]

El dataset de Steam no tiene red de usuarios (no hay respuestas, menciones ni interacciones entre autores de resenas), por lo que el analisis de red social no aplica a este corpus. En su lugar se implementan tres de los otros tipos de analisis que contempla el rubric: ANALISIS TEMPORAL, ANALISIS DE ENGAGEMENT y COMPARACION POR GRUPOS.

6.1 Agrupacion temporal por semana - justificacion

Todas las variables temporales se agrupan por SEMANA ISO (semanas que empiezan el lunes) en lugar de por dia o por mes. La eleccion de la granularidad temporal es una decision metodologica con impacto directo en la legibilidad de los resultados:

- DIARIO: el volumen diario de resenas es muy variable y ruidoso. Un dia puede tener 50 resenas y el siguiente 800 (por ejemplo, tras un parche o un fin de semana). El ruido ocultaria las tendencias reales.
- MENSUAL: demasiado grueso. Perderia variaciones importantes asociadas a eventos del juego como parches de actualizacion, lanzamiento de DLCs o periodos de descuento. Un mes de caida de sentimiento podria esconder una recuperacion parcial a mitad de mes.
- SEMANAL: suaviza el ruido diario y mantiene suficiente resolucion para detectar variaciones asociadas a eventos del ciclo de vida del juego. Es el equilibrio optimo para este corpus.

6.2 Analisis temporal - sentimiento y volumen (graficos 09 y 10)

El GRAFICO 09 usa un doble eje (`ax1.twinx()`): barras azules claras para el volumen de resenas semanales (eje izquierdo) y linea azul oscuro para el sentimiento medio semanal (eje derecho, `roberta_compound`). La razon de superponer ambas en la misma figura es ANALITICA: permite distinguir si una caida del sentimiento es una senal real o un artefacto del volumen. Si una semana tiene 50 resenas y el sentimiento cae a -0.3, la senal es debil (muestra pequena). Si tiene 3.000 resenas y el sentimiento cae a -0.3, la senal es robusta. La linea horizontal en $y=0$ marca la frontera entre territorio positivo y negativo.

HALLAZGO PRINCIPAL: Sentimiento positivo en las primeras semanas del lanzamiento (octubre-noviembre 2025), caida progresiva que cruza el cero en diciembre de 2025 y se mantiene en territorio negativo desde entonces. El pico de volumen de resenas coincide con el lanzamiento inicial. Un segundo pico notable en diciembre 2025 coincide con la introduccion de nuevos elementos de monetizacion (Battlepass de temporada).

El GRAFICO 10 muestra las PROPORCIONES normalizadas por tema por semana en lugar de conteos brutos. La normalizacion es necesaria porque el volumen varia mucho entre semanas: sin ella, la semana del lanzamiento dominaria visualmente por puro volumen aunque la distribucion de temas sea similar a otras semanas. Cada tema tiene un color fijo y consistente en todos los graficos del analisis complementario para facilitar la lectura cruzada entre figuras. El tema de comparacion con entregas anteriores (azul) domina practicamente todo el periodo con ~50% de proporcion semanal.

6.3 Analisis de engagement (graficos 11, 12 y 13)

Steam no tiene 'likes' en el sentido clasico de redes sociales, pero ofrece dos proxies de engagement: `playtime_hours` (implicacion del autor con el producto, medida en tiempo de uso real) y `weighted_vote_score` (validacion de la comunidad sobre la UTILIDAD de la resena, calculado por Steam con un algoritmo propio que evita el sesgo de popularidad).

CORRELACION PLAYTIME vs SENTIMIENTO:

- Se calcula regresion lineal simple con `scipy.stats.linregress` (Pearson) y correlacion de Spearman con `scipy.stats.spearmanr`. Se usan AMBAS porque la distribucion de horas jugadas tiene una cola muy larga: hay jugadores con 5.000+ horas que son outliers extremos.
- Pearson trabaja con los valores brutos y es sensible a outliers (un jugador con 8.000 horas puede distorsionar toda la correlacion calculada). Spearman trabaja con los rangos (orden relativo) y es robusto a outliers.

- Si Pearson y Spearman dan resultados similares, la correlacion es real y robusta. Si divergen significativamente, los outliers estan distorsionando Pearson.
- Con 91k puntos hay mucho solapamiento en el scatter plot: $\alpha=0.25$ hace los puntos semitransparentes para que las zonas densas sean visualmente mas oscuras, dando una imagen real de donde esta la masa de datos.

BOXPLOT DE HORAS (grafico 13): se recorta al percentil 95 de horas jugadas antes de dibujar el boxplot. Justificacion: sin el recorte, la escala del eje Y se extendera hasta 8.000 horas (outliers extremos) y la distribucion real donde el 95% de los jugadores tiene menos de ~400 horas quedara comprimida e ilegible en la base del grafico. El recorte no elimina datos del analisis estadistico, solo de la visualizacion. RESULTADO: mediana de 87 horas en resenas positivas vs 62 horas en negativas. Los jugadores mas comprometidos con el juego tienden a valorarlo mejor.

6.4 Comparacion por grupos voted_up (graficos 22 y 23)

El GRAFICO 22 muestra las proporciones de temas dominantes separadas por si la resena es un voto positivo (voted_up=True) o negativo (voted_up=False). Se usan proporciones normalizadas dentro de cada grupo porque hay mas resenas positivas que negativas: sin normalizacion, los temas de positivos tendrian barras mas altas simplemente por volumen, no por proporcion real. El porcentaje se anota directamente sobre cada barra para facilitar la lectura sin tener que estimar alturas.

HALLAZGOS CLAVE DE LA COMPARACION:

- Jugadores que VOTAN POSITIVO: 71.8% hablan principalmente de comparaciones con BF3 y BF4. El juego se valora como un retorno exitoso a las raices de la saga.
- Jugadores que VOTAN NEGATIVO: distribuyen entre problemas tecnicos (28.7%), mapas y vehiculos (19.4%) y monetizacion (19.2%). No hay un unico motivo dominante de insatisfaccion: los jugadores negativos tienen multiples quejas simultaneas.
- Mediana de horas jugadas: 87h en positivos vs 62h en negativos. Los jugadores con mas experiencia acumulada en el juego tienden a valorarlo mejor.

6.5 Heatmap sentimiento x tema (grafico 24 - visualizacion conclusion)

El GRAFICO 24 es la visualizacion conclusion que el rubric menciona explicitamente: la que conecta todos los hallazgos en una sola figura. Las filas son los 5 temas y las columnas los 3 sentimientos. Cada celda contiene el porcentaje de resenas de ese tema con ese sentimiento, normalizado por fila (cada fila suma 100%). El colormap RdYlGn va de rojo (porcentaje bajo) a verde (porcentaje alto). El color del texto dentro de cada celda cambia automaticamente segun la intensidad del fondo para garantizar legibilidad.

Tema	Neg.	Neu.	Pos.	%total
Comparacion con entregas anteriores	18.5%	15.7%	65.8%	54.8%
Mapas, armas y vehiculos	51.1%	14.9%	34.0%	13.6%
Mecanicas de combate y anti-cheat	57.9%	21.5%	20.6%	4.9%
Monetizacion y Battlepass	66.8%	16.9%	16.4%	9.9%
Problemas tecnicos y servidores	62.1%	15.1%	22.8%	16.9%

LECTURA DEL HEATMAP: La fila de Comparacion con entregas anteriores es abrumadoramente verde en la columna Positivo (65.8%): los jugadores que hablan de BF3/BF4 lo hacen mayoritariamente de forma positiva. Las filas de Monetizacion (66.8%) y Problemas tecnicos (62.1%) son abrumadoramente rojas en la columna Negativo: son las mayores fuentes de insatisfaccion. Esta tabla sintetiza en una sola imagen la respuesta a ambas preguntas de investigacion.

7. Resultados y conclusiones [1,0 pt]

7.1 Respuesta directa a las preguntas de investigacion

PREGUNTA 1: ¿Que características de Battlefield 6 generan mayor satisfaccion o insatisfaccion entre los jugadores de Steam?

RESPUESTA: Las mayores fuentes de INSATISFACCION son la monetizacion y el Battlepass (66.8% de reseñas sobre este tema son negativas) y los problemas técnicos y de servidores (62.1% negativas). Las mecánicas de combate y anti-cheat también son mayoritariamente negativas (57.9%). La mayor fuente de SATISFACCION es la comparacion favorable con entregas anteriores, especialmente BF3 y BF4: el 65.8% de las reseñas sobre este tema son positivas. El juego se percibe como un retorno exitoso a las raíces de la saga Battlefield, pero esta percepcion positiva convive con una fuerte insatisfaccion con el modelo de negocio y los problemas técnicos del lanzamiento.

PREGUNTA 2: ¿Como evoluciona el sentimiento de la comunidad a lo largo del tiempo?

RESPUESTA: El sentimiento comenzó en terreno positivo durante las primeras semanas del lanzamiento (octubre-noviembre 2025), con un promedio de roberta_compound positivo. Cayó de forma progresiva y cruzó el cero (punto neutro) en diciembre de 2025, coincidiendo con un pico notable en las reseñas sobre monetización. Desde enero de 2026 el sentimiento se mantiene en territorio negativo. El tema de comparacion con BF3/BF4 se mantiene dominante en proporción (~50%) durante todo el periodo, lo que indica que la narrativa de la comunidad es consistente: el juego recupera la esencia de la saga pero falla en su modelo de negocio y estabilidad técnica.

7.2 Hallazgos adicionales con cifras

- VOLUMEN: 168.341 reseñas extraídas; 91.197 limpias (54.2% de retención). Periodo completo de lanzamiento octubre 2025 - mayo 2026.
- SENTIMIENTO GLOBAL: RoBERTa clasifica aproximadamente el 45-50% de reseñas como negativas, 25-30% como positivas y el resto como neutras (distribución aproximada según los gráficos de sentimiento).
- MODELO: RoBERTa supera a VADER en todas las métricas: accuracy 78.87% vs 68.85%, precisión 93.58% vs 76.77%, F1 80.68% vs 74.08%.
- TEMAS: 5 temas con coherence $c_v = 0.6434$ (muy bueno). El 54.8% de reseñas se concentran en el tema de comparacion con entregas anteriores, lo que revela que la comunidad de Battlefield es altamente consciente de la historia de la saga.
- MULTITEMATICIDAD: el 76.1% de reseñas tienen al menos un tema secundario (umbral 0.20 de probabilidad), confirmando que los jugadores son analíticamente complejos en sus valoraciones.
- ENGAGEMENT: los jugadores que votan positivo tienen una mediana de 87 horas jugadas vs 62 horas en los que votan negativo. Mayor implicación con el juego correlaciona con mayor satisfacción.
- VALIDACION MANUAL: acuerdo del 80% entre RoBERTa y anotación humana (33/41 casos). Los casos de desacuerdo revelan limitaciones del modelo ante sarcasmo, hiperbole gaming y referencias culturales implícitas.

7.3 El heatmap como síntesis visual

La figura 24 (heatmap sentimiento x tema) es la visualización que concentra todos los hallazgos principales en una sola imagen. Para cada uno de los 5 temas descubiertos por el LDA, muestra con que sentimiento (positivo/neutral/negativo) hablan los jugadores sobre ese tema. La combinación de esta figura con los gráficos temporales (09 y 10) proporciona una visión completa tanto de QUE preocupa a la comunidad como de CUANDO cambia su percepción.

8. Limitaciones y sesgos del analisis

Todo análisis de datos tiene limitaciones. Identificarlas explícitamente es parte del rigor metodológico y permite al lector contextualizar los resultados correctamente:

- LIMITACION 1 - IDIOMA DEL CAMPO LANGUAGE: El campo language de Steam refleja el idioma de la interfaz del cliente Steam del usuario, no el idioma real del texto de la resena. Algunos jugadores hispanohablantes o lusohablantes con Steam en ingles escriben resenas en espanol o portugues que pasan el filtro. El impacto en un corpus de 91k resenas es marginal, pero implica que el corpus no es 100% en ingles. Se descarto langdetect por su alta tasa de falsos positivos en textos cortos.
- LIMITACION 2 - TRUNCADO DE 512 TOKENS EN ROBERTA: RoBERTa tiene un limite arquitectonico de 512 tokens de entrada. Las resenas largas (algunas con 800-1000 tokens) se truncan. Si el autor expresa su opinion principal al final de una resena muy larga, esa informacion se pierde para el analisis de sentimiento. En la practica, el impacto es menor porque la mayoria de resenas cortas de Steam caben en el limite, y en las largas la opinion suele expresarse desde el principio.
- LIMITACION 3 - GROUND TRUTH IMPERFECTO: voted_up es una valoracion binaria global del juego (¿lo recomiendas?), no una medicion del sentimiento del texto. Una resena puede tener texto predominantemente negativo pero voto positivo si el jugador recomienda el juego a pesar de sus defectos. Esto explica el recall de 70.9% de RoBERTa y es una limitacion inherente al uso de resenas como fuente de datos.
- LIMITACION 4 - SESGO DE SELECCION: Solo estan representados los jugadores motivados a escribir una resena en Steam. Los jugadores que jugaron y lo dejaron sin escribir nada (posiblemente los menos satisfechos o los mas indiferentes) no estan en el corpus. El dataset no representa a TODOS los jugadores de Battlefield 6, sino al subconjunto que decidio escribir y publicar una resena en Steam.
- LIMITACION 5 - LDA EN TEXTOS CORTOS: El LDA asume que cada documento es una mezcla de temas, pero en resenas muy breves (5-10 palabras tras la limpieza) hay escasez de vocabulario para hacer una asignacion fiable. Estas resenas tendran distribuciones de temas mas uniformes y menos informativas. Los parametros NO_BELOW=10 y NO_ABOVE=0.40 mitigan parcialmente este problema al forzar un vocabulario mas discriminativo.

9. Etica, privacidad y uso responsable

El analisis se realiza sobre datos obtenidos de la API PUBLICA OFICIAL de Steam, sin requerir autentificacion ni clave de API. Steam pone estos datos a disposicion publica de forma explicita para facilitar el estudio y la comunidad de su plataforma. No se accede a ningun dato de uso restringido ni se explota ninguna vulnerabilidad.

USO RESPONSABLE DE LA API: Se respetan los servidores de Steam mediante pausas de 1 segundo entre peticiones (time.sleep(1)), limitando la tasa a una peticion por segundo. Esto evita que la herramienta de extraccion pueda ser interpretada como un ataque de denegacion de servicio y respeta el espiritu de las condiciones de uso de Steam.

PRIVACIDAD: No se almacenan ni procesan nombres de usuario, identificadores de cuentas Steam ni ningun dato personal que permita identificar a los autores de las resenas. Solo se trabaja con el TEXTO de la resena y variables numericas anonimas (voted_up, playtime_hours, date, weighted_vote_score). Los datos son anonimos de facto para los propósitos de este analisis: no es posible ni se intenta identificar a ningun jugador especifico a partir del corpus procesado.

FINALIDAD: El analisis tiene finalidad exclusivamente ACADEMICA en el marco de la asignatura Analitica de Datos en la Web y Redes Sociales. Los resultados no se utilizan con fines comerciales ni se comparten fuera del contexto de evaluacion academica. Se cita la fuente (API de Steam, App ID 2807960) en todos los entregables del proyecto.

El proyecto cumple con los principios de uso etico de datos publicos establecidos por el rubric de la asignatura: API oficial, scraping responsable con pausas, anonimizacion de facto y finalidad academica declarada.

10. Reflexion final

10.1 Que hemos aprendido

- LAS STOPWORDS DE DOMINIO SON CRITICAS EN LDA: Esta es la leccion mas importante del proyecto. Sin filtrar los terminos de dominio ('game', 'play', 'battlefield', 'ea'), el LDA los pone con peso alto en todos los temas simultaneamente porque aparecen en practicamente todos los documentos. El resultado es que los temas no se distinguen: todos tienen el mismo vocabulario de alta frecuencia. La combinacion de tres capas de filtrado (stopwords de spaCy + Gaming Stopwords especificas + NO_ABOVE=0.40) es lo que permite al modelo encontrar los temas reales latentes en el corpus.
- LOS TRANSFORMERS SUPERAN A LOS DICCIONARIOS EN TEXTO INFORMAL: La diferencia entre RoBERTa (78.87% accuracy, 93.58% precision) y VADER (68.85% accuracy, 76.77% precision) es sustancial y consistente en todas las metricas. El procesamiento contextual de la frase completa (en lugar de la suma de puntuaciones de palabras individuales) marca una diferencia especialmente importante en textos con negaciones, sarcasmo y jerga gaming. El coste adicional (GPU, tiempo de inferencia, descarga del modelo) esta justificado por la mejora en calidad.
- EL GROUND TRUTH CONDICIONA EL ANALISIS: El pulgar arriba/abajo de Steam y el sentimiento del texto son conceptos distintos que no siempre coinciden. Esta limitacion del ground truth se refleja directamente en el recall de 70.9% de RoBERTa y fue uno de los hallazgos mas interesantes del proyecto: revelar que la comunidad de Battlefield 6 tiene resenas donde recomienda el juego a pesar de expresar insatisfaccion textual, lo que apunta a una satisfaccion condicional ('lo recomiendo aunque tenga problemas').
- EL COHERENCE SCORE ES INDISPENSABLE EN LDA: Sin una metrica objetiva de calidad de los temas, no hay forma de justificar la eleccion de k=5 temas sobre k=4 o k=6. El coherence score $c_v = 0.6434$ proporciona esa justificacion cuantitativa. Ademas, detectar que el valor original de NO_ABOVE=0.70 producía temas deficientes solo fue posible porque habia una metrica objetiva que reflejaba el problema. Sin el coherence score, el error podria haber pasado desapercibido.

10.2 Que cambariamos o mejorariamos

- BERTOPIC EN LUGAR DE LDA: BERTopic es una alternativa moderna al LDA que usa embeddings de frases (sentence-transformers) en lugar de bag-of-words. Es mas robusto con textos cortos (no pierde el orden de las palabras), no requiere especificar el numero de temas a priori (los descubre automaticamente) y produce temas mas coherentes en textos informales. El principal inconveniente es el mayor coste computacional (requiere GPU para los embeddings). Con el hardware disponible (RTX 4070) seria viable.
- VALIDACION MANUAL ANTES DEL ANALISIS FINAL: La validacion manual de 45 resenas se realizo como ultimo paso del pipeline, lo que limito su utilidad para retroalimentar el diseno del modelo. Realizarla antes (con una muestra piloto) habria permitido identificar los patrones de error del modelo (sarcasmo, hiperbole gaming) y ajustar el umbral de clasificacion o el preprocesamiento en consecuencia.
- DETECCION DE IDIOMA MEJORADA: En lugar de langdetect (alta tasa de falsos positivos en textos cortos), usar fastText language identification (modelo de Meta), que tiene una tasa de error mucho menor incluso en textos de 10-20 palabras. Esto permitiria filtrar las resenas en portugues y espanol que pasan el filtro de Steam actualmente.
- ANALISIS TEMPORAL POR PARCHE DEL JUEGO: El analisis temporal actual agrupa por semana ISO, lo que es util pero no captura la estructura real del ciclo de vida del juego. Combinando el timeline de parches y actualizaciones de Battlefield 6 con el dataset, seria posible analizar si cada parche mejoro o empeoro el sentimiento, y si los temas de queja cambiaron tras cada actualizacion. Este analisis 'event-driven' seria considerablemente mas informativo para el equipo de desarrollo del juego.

Memoria tecnica del proyecto: Analisis de resenas de Battlefield 6 en Steam

Analitica de Datos en la Web y Redes Sociales | Grado en Ingenieria Informatica | Mayo 2026

Pipeline: fetch_reviews.py -> data_cleaning.py -> roberta_sentiment.py -> topic_modeling.py -> complementary_analysis.py

Dataset: 168.341 reseñas raw | 91.197 reseñas limpias | Periodo: oct 2025 - may 2026 | App ID Steam: 2807960