

Análisis de reseñas de Battlefield 6 en Steam

Memoria Técnica del Pipeline de Análisis

Analítica de Datos en la Web y Redes Sociales
Grado en Ingeniería de Datos e Inteligencia Artificial
Jaime Alvarado Fernández · Pablo Ruiz Morán
Mayo 2026

Preguntas de investigación:

- 1. ¿Qué características de Battlefield 6 generan mayor satisfacción o insatisfacción entre los jugadores de Steam?*
- 2. ¿Cómo evoluciona el sentimiento de la comunidad a lo largo del tiempo desde el lanzamiento hasta mayo de 2026?*

1. Dataset y pregunta de investigación

1.1 Preguntas de investigación

El proyecto parte de dos preguntas de investigación complementarias que orientan todas las decisiones metodológicas posteriores:

- **PREGUNTA PRINCIPAL:** "¿Qué características de Battlefield 6 generan mayor satisfacción o insatisfacción entre los jugadores de Steam, y cómo evoluciona el sentimiento de la comunidad a lo largo del tiempo?"
- **PREGUNTA SECUNDARIA:** "¿Qué aspectos del juego aparecen con mayor frecuencia en las reseñas negativas de Battlefield 6 en Steam y que diferencia a los jugadores que recomiendan el juego de los que no lo recomiendan?"

1.2 Por qué Steam como fuente de datos

La API publica de Steam (store.steampowered.com/appreviews/2807960, donde 2807960 es el App ID de Battlefield 6) ofrece varias ventajas decisivas frente a otras fuentes alternativas como Twitter/X, Reddit o foros de usuarios:

- *API oficial y pública:* No requiere autenticación ni clave de API y las peticiones son reproducibles por cualquier investigador, garantizando la trazabilidad del dataset.
- *Datos estructurados:* Cada reseña incluye el texto libre y también metadatos cuantitativos (horas jugadas, voto de utilidad de la comunidad, fecha exacta) que permiten análisis de engagement imposibles con otras fuentes.
- *Volumen elevado:* 168.341 reseñas en brutom, lo que garantiza suficiente representatividad estadística para todos los subgrupos de análisis.
- *Ground truth integrado:* El campo voted_up (pulgar arriba/abajo) proporciona una etiqueta de sentimiento binaria asignada por el propio autor, sin necesidad de anotación manual.
- *Cobertura temporal:* El dataset abarca desde el lanzamiento del juego (octubre 2025) hasta mayo de 2026, cubriendo el ciclo de vida inicial completo con eventos clave como parches y actualizaciones de contenido.

1.3 Volumen y periodo del dataset

Métrica	Valor
Reseñas extraídas	168.341
Reseñas tras preprocesado	91.197
Tasa de retención	54.2% (91.197 / 168.341)
Periodo de análisis	Octubre 2025 - Mayo 2026
Idioma del corpus	Inglés (filtrado por campo language de Steam)

1.4 Variables del dataset limpio

El dataset final (**battlefield6_reviews_clean.csv**) contiene las siguientes variables, seleccionadas y transformadas del

original para maximizar su utilidad analítica:

Variable	Descripción	Uso en el análisis
<code>voted_up</code>	Pulgar arriba (True) o abajo (False) asignado por el autor de la reseña	Ground truth para evaluar los modelos de sentimiento
<code>playtime_hours</code>	Horas jugadas por el autor en el momento de la reseña (minutos / 60)	Variable de engagement utilizada en el análisis complementario
<code>date</code>	Fecha de publicación de la reseña (convertida desde Unix timestamp)	Análisis temporal semanal (gráficos 09 y 10)
<code>weighted_vote_score</code>	puntuación ponderada de Steam (0 a 1) sobre la utilidad de la reseña	Proxy de utilidad percibida por la comunidad
<code>text_cleaned</code>	Texto limpio y legible, con palabras en minúsculas, sin URLs ni caracteres especiales	Entrada a RoBERTa para el análisis de sentimiento
<code>text_lemmatized</code>	Texto lematizado, sin stopwords ni términos de dominio gaming	Entrada al LDA para el modelado de temas

2. Obtención y documentación de datos

2.1 Mecanismo de extracción: paginación por cursor

El script `fetch_reviews.py` hace peticiones paginadas a la API de Steam usando el sistema de cursor. A diferencia de una paginación clásica por número de página, la API de Steam devuelve en cada respuesta un token (cursor) que apunta internamente a la siguiente página de resultados, evitando así, problemas de páginas solapadas cuando se insertan nuevas reseñas durante la extracción.

El bucle de extracción comienza con una primera petición con `cursor=*` (inicio), con la que se reciben hasta 100 reseñas por petición, se extrae el nuevo cursor de la respuesta y se usa en la siguiente petición. El bucle termina cuando el cursor recibido es idéntico al de la petición anterior o viene vacío, lo que indica que se han agotado todas las páginas disponibles.

Además, entre cada petición hay una pausa explícita de 1 segundo para respetar los servidores de Steam y evitar scraping agresivo. Con 168.341 reseñas y 100 por petición, la extracción completa requiere ~1.684 peticiones y tarda aproximadamente 28 minutos.

2.2 Campos extraídos de la API

Por cada reseña, la API devuelve un objeto JSON del que se extraen los siguientes campos y se realizan las conversiones necesarias:

Campo API	Tipo original	Transformación aplicada
<code>review_id</code>	Entero	Identificador único, no se usa en análisis
<code>review (text)</code>	String	Campo principal que se limpia y lematiza
<code>language</code>	String	Solo se conservan 'english'
<code>voted_up</code>	Boolean	Ground truth para evaluación de modelos
<code>timestamp_created</code>	Unix epoch (int)	<code>pd.to_datetime(..., unit='s')</code> -> fecha
<code>playtime_forever</code>	Minutos (int)	Dividido entre 60, redondeado a 2 decimales

<code>votes_helpful</code>	Entero	No usado en análisis final
<code>votes_funny</code>	Entero	No usado en análisis final
<code>weighted_vote_score</code>	Float 0-1	Valor de utilidad en análisis de engagement

2.3 Limitación documentada: el problema del campo `language`

El campo `language` de la API de Steam refleja el idioma configurado en el cliente Steam del usuario, no el idioma real del texto de la reseña, lo que tiene una limitación importante ya que si un jugador hispanohablante que tiene su cliente Steam configurado en inglés escribió su reseña en español, el campo `language` lo indicará como `english`.

Se evaluó usar la librería **langdetect** para detectar automáticamente el idioma real del texto y rechazar las reseñas no inglesas. Sin embargo, **langdetect** fue descartada por dos razones técnicas concretas:

- Alta tasa de falsos positivos en textos cortos
- La clasificación errónea eliminaría reseñas validas del corpus, reduciendo el volumen de datos sin garantía de mayor pureza lingüística.

3. Preprocesamiento

3.1 Por qué spaCy y no NLTK

La elección de spaCy con el modelo `en_core_web_sm` frente a NLTK responde a dos ventajas técnicas específicas relevantes para este proyecto:

- **Lematización contextual:** spaCy realiza tokenización y lematización en una sola pasada sobre el documento mediante un pipeline interno que incluye POS tagging (etiquetado de categorías gramaticales). Esto permite lematizar correctamente según el contexto. Por ejemplo, la palabra 'better' se convierte en 'good' si el POS tag es adjetivo (ADJ), pero en 'better' si se usa como verbo auxiliar. NLTK con PorterStemmer solo trunca morfológicamente ('running' -> 'run' por corte del sufijo '-ing') sin entender el contexto gramatical, lo que genera formas base incorrectas con frecuencia.
- **Stopwords integradas:** spaCy tiene un modelo preentrenado con las stopwords del inglés integradas como propiedad del token (`token.is_stop = True/False`), por lo que no es necesario gestionar ni importar una lista separada.
- **Velocidad:** El modelo `en_core_web_sm` es significativamente más rápido que las alternativas puras de Python de NLTK para corpus grandes.

3.2 Bloque 1 - Filtrado de reseñas

Antes de transformar el texto, se descartan reseñas enteras que no aportaran nada útil al análisis. Este filtrado previo evita malgastar tiempo de CPU/GPU en la lematización y la inferencia de RoBERTa sobre reseñas que de todos modos se eliminarían después. Se aplican cuatro filtros en cascada:

FILTRO 1 - Idioma:

Se comprueba el campo `language` y si no es 'english' (ignorando mayúsculas y espacios), la

reseña se descarta. El valor por defecto si el campo falta es 'english' para no eliminar reseñas validas por un campo ausente en la API. Este filtro elimina las 2 reseñas explícitamente en japones y turco.

FILTRO 2 - Emojis puros:

Algunas reseñas de Steam consisten literalmente en uno o varios emojis sin ningún texto (por ejemplo, solo tres llamas o un pulgar arriba). Estas reseñas no aportan información textual para ni RoBERTa ni el LDA. El filtro aplica una regex y comprueba si queda algún carácter alfanumérico tras eliminar los emojis, de forma que si el texto resultante está vacío, la reseña se descarta.

FILTRO 3 - Calidad mínima (5 palabras):

Se requieren al menos 5 palabras en el texto limpio, descartandovreseñas de una o dos palabras ('good game', 'trash'), reseñas compuestas solo de números y símbolos ('10/10!!!') que no aportan texto analizable, y reseñas de spam donde una misma palabra se repite más de 5 veces.

FILTRO 4 - Spam (palabra repetida > 5 veces):

Se usa Counter(words).values() y se comprueba que el máximo no supera 5, logrando eliminar reseñas tipo 'hahahahahahaha' o '!!!!!!!!!!!!!!' que son ruido puro y podrían distorsionar las distribuciones de palabras del LDA si se incluyeran en el corpus.

3.3 Bloque 2 - Limpieza del texto

El texto crudo que pasa los filtros anteriores se limpia en cuatro pasos secuenciales. El resultado se guarda en la columna `text_cleaned`, que es la versión que usa RoBERTa:

Operación	Técnica	Justificación
Minúsculas	<code>text.lower()</code>	Normaliza 'Game', 'GAME' y 'game' a la misma forma. Necesario antes de cualquier comparación léxica.
Eliminar URLs	regex <code>https?://[A-Za-z0-9\.\s]+</code> sustituida por espacio	Los enlaces no aportan contenido semántico. Se sustituye por espacio (no vacío) para no fusionar las palabras adyacentes.
Eliminar caracteres especiales	regex <code>^[a-z0-9\s.,;:?!]</code> sustituida por espacio	Conserva letras, números y puntuación básica. Los hashtags se eliminan: en Steam no tienen valor temático como en Twitter.
Colapsar espacios	regex <code>\s+ -> ' '</code>	Elimina espacios múltiples, tabs y saltos de línea resultantes de los pasos anteriores.

3.4 Bloque 3 - Lematización y gestion de negaciones

El texto limpio se procesa con spaCy para generar la columna `text_lemmatized`, que es la que usa el LDA. Este paso tiene una complejidad adicional al lidiar con las negaciones.

Si se lematiza y eliminan stopwords de manera estándar, 'not' desaparece porque es una stopword en spaCy, de forma que el resultado es que 'the game is not good' y 'the game is good' producen exactamente el mismo texto lematizado: 'game good', por lo que el LDA no podría distinguir entre una valoración positiva y una negativa.

La solución fue usar bigramas del estilo **not_X**. De esta forma cuando encuentra el token 'not' seguido de una palabra que no es puntuación, construye un bigrama concatenando 'not_' con el lema del token siguiente y avanza el índice en 2 posiciones en lugar de 1.

3.5 Bloque 4 - Gaming Stopwords (stopwords de dominio)

spaCy elimina las stopwords del inglés general, pero no sabe que en este corpus concreto ciertas palabras son igualmente poco informativas. Palabras como 'game', 'play' o 'battlefield' aparecen en prácticamente todas las reseñas de Steam de cualquier Battlefield, sin discriminar entre temas. Si se dejan en el vocabulario, el LDA las encontrara con peso alto en todos los temas simultáneamente, eliminando la separación semántica entre ellos.

Lista completa de Gaming Stopwords anadidas:

- Terminus genericos del videojuego: game, play, battlefield, fun, great, good, bad
- Verbos auxiliares muy frecuentes: get, make, go, think, know, want, need, give, come, look, say
- Nombres propios del ecosistema Battlefield: bf, ea, dice
- Sustantivos abstractos sin valor discriminativo: lot, time, way, thing, people, player, year
- Adjettivos y adverbios genericos: like, feel

3.6 Resultado del preprocesamiento

De 168.341 reseñas se pasa a 91.197 reseñas limpias (tasa de retencion: 54.2%). Las aproximadamente 77.000 reseñas eliminadas corresponden a:

- Reseñas de idioma no inglés (campo language != 'english'): 2 reseñas (japones, turco)
- Reseñas con menos de 5 palabras tras la limpieza: la mayoría de las eliminadas
- Reseñas de solo emojis o de solo números/símbolos: varios miles
- Reseñas con spam repetitivo (palabra repetida > 5 veces): algunas centenas
- Reseñas cuya lematización produce texto vacío (texto que era 100% stopwords): residual

4. Análisis de sentimiento

4.1 Por qué dos modelos

Se implementaron dos modelos (VADER y RoBERTa) para poder comparar cuantitativamente cual funciona mejor, con métricas reales calculadas frente al mismo ground truth. El modelo ganador (RoBERTa) se usa como columna principal (roberta_sentiment). VADER queda en el CSV para comparación y como ilustración de las limitaciones de los enfoques basados en diccionario.

4.2 Modelo 1 - VADER

VADER es un diccionario léxico con reglas heurísticas diseñado para texto de redes sociales que puntúa cada token según su valencia, aplica modificadores para mayúsculas, exclamaciones y negaciones, y normaliza el resultado a un score compound de -1 a +1. Como ventajas, es instantáneo, no requiere GPU y es interpretable. Sin embargo, presenta una serie de limitaciones, ya que puntúa token a token sin contexto de frase, falla en negaciones compuestas, sarcasmo y jerga gaming ('this game is cancer' -> neutral en VADER, muy negativo para la comunidad).

4.3 Modelo 2 - RoBERTa

A diferencia de VADER, procesa la frase completa como una unidad mediante capas de atención: 'not bad' y 'bad' producen representaciones distintas porque el modelo ha aprendido esa construcción sobre millones de ejemplos reales.

Se usó este modelo porque:

- Está entrenado en tweets, que son textos informales, cortos y llenos de jerga, exactamente igual que las reseñas de Steam. Un modelo entrenado en noticias o artículos académicos (como BERT-base sin fine-tuning) rendiría peor en este corpus.
- Tiene tres clases (positive/neutral/negative) en lugar de dos (positive/negative) lo que lo hace más adecuado para reseñas donde el tono ambivalente es muy frecuente.

Sin embargo, las reseñas largas (800-1000 tokens) se truncan con `truncation=True`, `max_length=512`, lo que lo convierte en una limitación, al eliminar algunos tokens del análisis.

El modelo devuelve una etiqueta categórica (positive/neutral/negative) y un score de confianza entre 0 y 1. Con eso solo se tiene información categórica, insuficiente para análisis de correlación con variables numéricas continuas (horas jugadas, fecha, vote score). Es por ello que se construye la variable **roberta_compound** entre -1 y +1: si la etiqueta es 'positive', el compound es +score (positivo con 95% de confianza -> +0.95); si es 'negative', el compound es -score (negativo con 80% -> -0.80); si es 'neutral', el compound es 0.0. Esto es análogo al compound de VADER y permite tratar el sentimiento como una variable continua en todos los análisis posteriores.

4.4 Métricas de evaluación y comparativa

Para evaluar ambos modelos se usa **voted_up** como ground truth. La lógica es: si un jugador pulso el pulgar arriba, asumimos que su reseña expresa sentimiento positivo; si pulso pulgar abajo, sentimiento negativo.

Métrica	VADER	RoBERTa (modelo principal)
Tipo de modelo	Diccionario léxico + reglas heurísticas	Transformer fine-tuned (58M tweets)
Accuracy	68.85%	78.87%
Precisión	76.77%	93.58%
Recall	71.58%	70.90%
F1-score	74.08%	80.68%

- Accuracy 78.87% vs 68.85%: RoBERTa acierta en 10 puntos porcentuales más de reseñas.
- Precisión 93.58%: cuando RoBERTa dice que una reseña es positiva, casi siempre tiene razón. Muy pocos falsos positivos. VADER tiene 16 puntos menos de precisión (76.77%).
- Recall 70.90% (similar en ambos): muchas reseñas donde el jugador voto positivo (`voted_up=True`) tienen texto con sentimiento mixto o negativo. El modelo las clasifica como negativas o neutrales, lo que cuenta como fallo de recall aunque el modelo puede estar 'en lo correcto' respecto al te

4.5 Validación manual (41 reseñas anotadas)

El script `manual_validation.py` genera una muestra estratificada de 45 reseñas dividida en tres grupos: acuerdo positivo (RoBERTa y voted_up coinciden en positivo), acuerdo negativo y desacuerdo (divergen). El objetivo es identificar PATRONES DE ERROR del modelo que las métricas globales no revelan. Se anotaron 41 de las 45 reseñas:

Grupo	N	Resultado
Coincidencia positiva (RoBERTa = Steam = positivo)	15	15/15 (100%) de acuerdo
Coincidencia negativa (Steam negativo + RoBERTa)	15	15/15 (100%) de acuerdo
Desacuerdo (casos difíciles para el modelo)	11	3/11 (27%) de acuerdo
TOTAL anotado	41	33/41 (80%) de acuerdo global

Patrones de error identificados:

- *Sarcasmo*: 'buy baitandswitch 6 [...] servers hosted with windows 95' -> RoBERTa lo clasifica como positivo leyendo literalmente 'buy' como acto de compra voluntaria. Esto ocurre porque el sarcasmo requiere conocimiento del contexto cultural que el modelo no tiene.
- *Bipolaridad*: 'getting bent over a table by an attack helicopter [...] i love this game' -> el texto es muy negativo en tono pero el jugador vota positivo. El modelo no entiende que en la cultura gaming la queja puede coexistir con el disfrute.
- *Referencias pasadas*: 'just like the good ol days' -> RoBERTa dice neutral. Sin saber que hace referencia positiva a BF3/BF4, la frase parece ambigua.
- *Comentarios sin sentido*: 'id play with my dead grandma but shes dead so that wont work' -> ni el modelo ni el anotador humano pueden determinar el sentimiento con certeza. Estos casos ilustran los límites del análisis de sentimiento automático.

5. Modelado de temas - LDA (Gensim)

5.1 Preparación del vocabulario: filter_extremes

Antes de entrenar el LDA, se construye el diccionario de Gensim y se filtra con `filter_extremes(no_below=10, no_above=0.40)`. Este es uno de los pasos más críticos del pipeline:

- `NO_BELOW=10`: se eliminan los tokens que aparecen en menos de 10 documentos. Con 91k reseñas, si una palabra aparece solo en 3-4, es casi con certeza una errata o un término tan específico que no puede generar un tema coherente.
- `NO_ABOVE=0.40`: se eliminan los tokens que aparecen en más del 40% de los documentos. Este fue el parámetro más crítico, ya que inicialmente, el valor original era 0.70, que dejaba pasar palabras como 'game' (que aparece en ~55% de los docs) o 'play' (~45%).

5.2 Parámetros del modelo LDA y justificación

Parámetro	Valor	Justificación detallada
num_topics	5	Se probaron 4 y 6 temas. Con 4, dos temas técnicamente distintos se fusionaban. Con 6, un tema extra era semánticamente redundante con otro. Con 5, el coherence score era máximo (0.6434) y los temas eran distinguibles.
passes	15	Con 10 pasadas los temas eran inestables entre ejecuciones y con 15 pasadas, se garantizaba convergencia para un corpus de 91k docs.
chunksize	2000	Número de documentos procesados por iteración. Valor original de 100 era ineficiente con 91k docs (demasiados microlotes). 2000 equilibra velocidad y calidad de convergencia.
NO_ABOVE	0.40	Filtra tokens en más del 40% de documentos. Valor crítico: 0.70 original causaba que el 98% de reseñas cayeran en un tema.
NO_BELOW	10	Descarta tokens en menos de 10 reseñas. Con 91k docs, requiere cierta frecuencia mínima para tener señal estadística.
alpha='auto'	-	El modelo aprende la distribución óptima de temas por documento en lugar de asumir valores fijos (simétrico por defecto).
eta='auto'	-	El modelo aprende la distribución óptima de palabras por tema.
random_state	42	LDA es estocástico (inicialización aleatoria de asignaciones). Semilla fija garantiza reproducibilidad exacta entre ejecuciones.

5.3 Coherence score c_v : 0.6434

El coherence score mide la calidad semántica de los temas descubiertos, midiendo si las palabras más representativas de cada tema co-ocurren frecuentemente en el corpus real. Si las palabras clave del tema de monetización ('pay', 'skin', 'money', 'battlepass') aparecen juntas frecuentemente en las reseñas reales, el tema es semanticamente coherente y tiene sentido interpretarlo como una unidad temática real.

Escala de referencia para c_v :


Rango c_v	Interpretación
< 0.40	Malo: los temas no tienen coherencia semántica interpretable
0.40 - 0.50	Aceptable: temas distinguibles, pero con solapamiento
0.50 - 0.60	Bueno: temas claros con vocabulario diferenciado
> 0.60	Muy bueno: temas altamente coherentes (nuestro resultado: 0.6434)

5.4 Los 5 temas descubiertos

#	Etiqueta asignada	Palabras clave reales del modelo	Reseñas	%
0	Comparación con entregas	cod, bf4, bf3, 2042, campaign,	49.958	54.8%
1	Mecánicas de combate y anti-cheat	kill, hit, tank, die, shoot, spawn, cheater,	4.451	4.9%
2	Mapas, armas y vehiculos	map, mode, gun, weapon, vehicle, big,	12.362	13.6%
3	Problemas técnicos y servidores	not_fix, issue, bug, server, run, launch	15.386	16.9%
4	Monetización y Battlepass	battle, buy, skin, money, pass, pay,	9.040	9.9%

5.5 Visualización pyLDAvis

pyLDAvis genera una visualización interactiva con dos paneles. El panel izquierdo muestra los 5 temas como círculos en un espacio bidimensional calculado con MDS (Multi-Dimensional Scaling). Las distancias entre círculos reflejan la similitud semántica entre temas, donde los círculos alejados tienen vocabularios poco solapados (temas bien separados). El tamaño de cada círculo es proporcional al peso del tema en el corpus (el tema 0 es el más grande porque representa el 54.8% de las reseñas). El panel derecho muestra los términos más relevantes del tema seleccionado, con la frecuencia global en gris y la frecuencia específica del tema en azul.



6. Análisis complementario

El dataset de Steam no tiene red de usuarios (no hay respuestas, menciones ni interacciones entre autores de reseñas), por lo que el análisis de red social no aplica a este corpus. En su lugar se implementan tres de los otros tipos de análisis.

6.1 Agrupación temporal por semana - justificación

Todas las variables temporales se agrupan por semanas en lugar de por día o por mes. La elección de la granularidad temporal es una decisión metodológica con impacto directo en la legibilidad de los resultados:

- **Diario:** el volumen diario de reseñas es muy variable y ruidoso. Un día puede tener 50 reseñas y el siguiente 800 (por ejemplo, tras un parche o un fin de semana). El ruido ocultaría las tendencias reales.
- **Mensual:** demasiado grueso. Perdería variaciones importantes asociadas a eventos del juego como parches de actualización, lanzamiento de DLCs o periodos de descuento. Un mes de caída de sentimiento podría esconder una recuperación parcial a mitad de mes.
- **Semanal:** suaviza el ruido diario y mantiene suficiente resolución para detectar variaciones asociadas a eventos del ciclo de vida del juego. Es el equilibrio óptimo para este corpus.

6.2 Análisis temporal - sentimiento y volumen (gráficos 9 y 10)

El gráfico 9 usa barras azules claras para el volumen de reseñas semanales (eje izquierdo) y una línea azul oscuro para el sentimiento medio semanal (eje derecho, roberta_compound). La razón de superponer ambas en la misma figura es poder distinguir si una caída del sentimiento es una señal real o un artefacto del volumen. Si una semana tiene 50 reseñas y el sentimiento cae a -0.3, la señal es débil (muestra pequeña). En cambio, si tiene 3.000 reseñas y el sentimiento cae a -0.3, la señal es robusta. La línea horizontal en y=0 marca la frontera entre territorio positivo y negativo.

Se observó un sentimiento positivo en las primeras semanas del lanzamiento (octubre-noviembre 2025), una caída progresiva que cruza el cero en diciembre de 2025 y se mantiene en territorio negativo desde entonces. El pico de volumen de reseñas coincide con el lanzamiento inicial. Un segundo pico notable en diciembre 2025 coincide con la introducción de nuevos elementos de monetización (Battlepass de temporada).

Por otra parte, el gráfico 10 muestra las proporciones normalizadas por tema por semana en lugar de conteos brutos. La normalización es necesaria porque el volumen vario mucho entre semanas, ya que sin ella, la semana del lanzamiento dominaría visualmente por puro volumen aunque la distribución de temas sea similar a otras semanas.

6.3 Análisis de engagement (gráficos 11, 12 y 13)

Steam no tiene 'likes' en el sentido clásico de redes sociales, pero ofrece dos proxies de engagement, **playtime_hours** (implicación del autor con el producto, medida en tiempo de uso real) y **weighted_vote_score** (validación de la comunidad sobre la UTILIDAD de la reseña, calculado por Steam con un algoritmo propio que evita el sesgo de popularidad).

Correlación *PLAYTIME* vs *SENTIMIENTO*:

- Se calcula regresión lineal simple con y correlación de Spearman porque la distribución de horas jugadas tiene una cola muy larga: hay jugadores con 5.000+ horas que son outliers extremos.
- Si Pearson y Spearman dan resultados similares, la correlación es real y robusta. Si divergen significativamente, los outliers están distorsionando Pearson.

Finalmente, se concluye que los jugadores más comprometidos con el juego tienden a valorarlo mejor.

6.4 Comparación por grupos *voted_up* (gráficos 22 y 23)

El gráfico 22 muestra las proporciones de temas dominantes separadas por si la reseña es un voto positivo (*voted_up=True*) o negativo (*voted_up=False*). Se usan proporciones normalizadas dentro de cada grupo porque hay más reseñas positivas que negativas: sin normalización, los temas de positivos tendrían barras más altas simplemente por volumen, no por proporción real. El porcentaje se anota directamente sobre cada barra para facilitar la lectura sin tener que estimar alturas.

Se observa que:

- Jugadores que votan positivo: 71.8% hablan principalmente de comparaciones con BF3 y BF4. El juego se valora como un retorno exitoso a las raíces de la saga.
- Jugadores que votan negativo: distribuyen entre problemas técnicos (28.7%), mapas y vehiculos (19.4%) y monetización (19.2%). No hay un único motivo dominante de insatisfacción: los jugadores negativos tienen múltiples quejas simultáneas.
- Mediana de horas jugadas: 87h en positivos vs 62h en negativos. Los jugadores con más experiencia acumulada en el juego tienden a valorarlo mejor.

6.5 Heatmap sentimiento po tema (gráfico 24 - visualización conclusión)

Es la visualización conclusión que conecta todos los hallazgos en una sola figura. Las filas son los 5 temas y las columnas los 3 sentimientos. Cada celda contiene el porcentaje de reseñas de ese tema con ese sentimiento, normalizado por fila (cada fila suma 100%). El colormap RdYlGn va de rojo (porcentaje bajo) a verde (porcentaje alto).

Tema	Neg.	Neu.	Pos.	%total
Comparación con entregas anteriores	18.5%	15.7%	65.8%	54.8%
Mapas, armas y vehiculos	51.1%	14.9%	34.0%	13.6%
Mecanicas de combate y anti-cheat	57.9%	21.5%	20.6%	4.9%
Monetización y Battlepass	66.8%	16.9%	16.4%	9.9%
Problemas técnicos y servidores	62.1%	15.1%	22.8%	16.9%

La fila de *Comparación con entregas anteriores* es abrumadoramente verde en la columna Positivo (65.8%): los jugadores que hablan de BF3/BF4 lo hacen mayoritariamente de forma positiva. Las filas de Monetización (66.8%) y Problemas técnicos (62.1%) son abrumadoramente rojas en la columna Negativo: son las mayores fuentes de

insatisfacción. Esta tabla sintetiza en una sola imagen la respuesta a ambas preguntas de investigación.

7. Resultados y conclusiones

7.1 Respuesta directa a las preguntas de investigación

PREGUNTA 1: ¿Qué características de Battlefield 6 generan mayor satisfacción o insatisfacción entre los jugadores de Steam?

Las mayores fuentes de insatisfacción son la monetización y el Battlepass (66.8% de reseñas sobre este tema son negativas) y los problemas técnicos y de servidores (62.1% negativas). Las mecánicas de combate y anti-cheat también son mayoritariamente negativas (57.9%). Por el contrario, la mayor fuente de satisfacción es la comparación favorable con entregas anteriores, especialmente BF3 y BF4: el 65.8% de las reseñas sobre este tema son positivas. El juego se percibe como un retorno exitoso a las raíces de la saga Battlefield, pero esta percepción positiva convive con una fuerte insatisfacción con el modelo de negocio y los problemas técnicos del lanzamiento.

PREGUNTA 2: ¿Cómo evoluciona el sentimiento de la comunidad a lo largo del tiempo?

El sentimiento comenzó en terreno positivo durante las primeras semanas del lanzamiento (octubre-noviembre 2025), pero cayó de forma progresiva y cruzó el punto neutro en diciembre de 2025, coincidiendo con un pico notable en las reseñas sobre monetización. Desde enero de 2026 el sentimiento se mantiene en territorio negativo. El tema de comparación con BF3/BF4 se mantiene dominante en proporción (~50%) durante todo el periodo, lo que indica que la narrativa de la comunidad es consistente: el juego recupera la esencia de la saga pero falla en su modelo de negocio y estabilidad técnica.

7.2 Hallazgos adicionales con cifras

- *Volumen*: 168.341 reseñas extraídas; 91.197 limpias (54.2% de retención). Periodo completo de lanzamiento octubre 2025 - mayo 2026.
- *Sentimiento Global*: RoBERTa clasifica el 47.1% de reseñas como positivas, el 37.0% como negativas y el 15.9% como neutras (sobre las 91.197 reseñas del corpus).
- *Comparativa Modelos*: RoBERTa supera a VADER en todas las métricas: accuracy 78.87% vs 68.85%, precisión 93.58% vs 76.77%, F1 80.68% vs 74.08%.
- *Temas*: 5 temas con coherence $c_v = 0.6434$, de los cuales el tema de comparación con entregas anteriores concentra el 54.8% de reseñas, lo que revela que la comunidad de Battlefield es altamente consciente de la historia de la saga.
- *Multitemacidad*: el 76.1% de reseñas tienen al menos un tema secundario (umbral 0.20 de probabilidad), confirmando que los jugadores son analíticamente complejos en sus valoraciones.
- *Engagement*: los jugadores que votan positivo tienen una mediana de 87 horas jugadas vs 62 horas en los que votan negativo, de forma que mayor implicación con el juego correlaciona con mayor satisfacción.
- *Validación manual*: Los casos de desacuerdo revelan limitaciones del modelo ante sarcasmo, hipérbole gaming y referencias culturales implícitas.

8. Ética, privacidad y uso responsable

El análisis se realiza sobre datos obtenidos de la API pública oficial de Steam, sin requerir autenticación ni clave de API. Steam pone estos datos a disposición pública de forma explícita para facilitar el estudio y la comunidad de su plataforma. No se accede a ningún dato de uso restringido ni se explota ninguna vulnerabilidad.

Se respetan los servidores de Steam mediante pausas de 1 segundo entre peticiones, limitando la tasa a una petición por segundo. Esto evita que la herramienta de extracción pueda ser interpretada como un ataque de denegación de servicio y respeta el espíritu de las condiciones de uso de Steam.

Tampoco se almacenan ni procesan nombres de usuario, identificadores de cuentas Steam ni ningún dato personal que permita identificar a los autores de las reseñas. Solo se trabaja con el TEXTO de la reseña y variables numéricas

anónimas. Los datos son anónimos de facto para los propósitos de este análisis: no es posible ni se intenta identificar a ningún jugador específico a partir del corpus procesado.

9. Reflexión final

9.1 ¿Qué hemos aprendido

- Las stopwords de dominio son críticas. Sin filtrar los términos de dominio ('game', 'play', 'battlefield', 'ea'), el LDA los pone con peso alto en todos los temas simultáneamente porque aparecen en prácticamente todos los documentos. El resultado es que los temas no se distinguen, ya que todos tienen el mismo vocabulario de alta frecuencia. La combinación de tres capas de filtrado (stopwords de spaCy + Gaming Stopwords específicas + NO_ABOVE=0.40) es lo que permite al modelo encontrar los temas reales latentes en el corpus.
- Los Transformers superan a los diccionarios: La diferencia entre RoBERTa y VADER es sustancial y consistente en todas las métricas. El procesamiento contextual de la frase completa (en lugar de la suma de puntuaciones de palabras individuales) marca una diferencia especialmente importante en textos con negaciones, sarcasmo y jerga gaming. El coste adicional (GPU, tiempo de inferencia, descarga del modelo) está justificado por la mejora en calidad.
- EL ground truth condiciona el análisis: El pulgar arriba/abajo de Steam y el sentimiento del texto son conceptos distintos que no siempre coinciden. Esta limitación del ground truth se refleja directamente en el recall de RoBERTa al revelar que la comunidad tiene reseñas donde recomienda el juego a pesar de expresar insatisfacción textual.
- El coherence score es fundamental en LDA: Sin una métrica objetiva de calidad de los temas, no hay forma de justificar la elección de $k=5$ temas sobre $k=4$ o $k=6$. El coherence score $c_v = 0.6434$ proporciona esa justificación cuantitativa. Además, detectar que el valor original de NO_ABOVE=0.70 producía temas deficientes solo fue posible porque había una métrica objetiva que reflejaba el problema. Sin el coherence score, el error podría haber pasado desapercibido.

9.2 ¿Qué cambiaríamos o mejoraríamos?

- BERTopic en lugar de LDA: BERTopic es una alternativa moderna al LDA que usa embeddings de frases (sentence-transformers) en lugar de bag-of-words, siendo más robusto con textos cortos (no pierde el orden de las palabras), no requiere especificar el número de temas a priori (los descubre automáticamente) y produce temas más coherentes en textos informales. El principal inconveniente es el mayor coste computacional (requiere GPU para los embeddings).
- Detección de idioma mejorada: En lugar de langdetect (alta tasa de falsos positivos en textos cortos), usar fastText language identification (modelo de Meta), que tiene una tasa de error mucho menor incluso en textos de 10-20 palabras, permitiendo filtrar las reseñas en portugués y español que pasan el filtro de Steam actualmente.
- Análisis temporal por parche de juego: El análisis temporal actual agrupa por semana, lo que es útil pero no captura la estructura real del ciclo de vida del juego. Combinando el timeline de parches y actualizaciones de Battlefield 6 con el dataset, sería posible analizar si cada parche mejora o empeora el sentimiento, y si los temas de queja cambiaron tras cada actualización. Este análisis sería considerablemente más informativo para el equipo de desarrollo del juego.